

Veja discussões, estatísticas e perfis de autor para esta publicação em: <https://www.researchgate.net/publication/343714117>

Previsão de Paradas Operacionais de Brigadas de Incêndio: Um Estudo de Caso Real

Artigo · Agosto de 2020

DOI: 10.3390/math8081383

CITAÇÕES

13

LER

289

5 autores, incluindo:



Selene Leya Cerna Nahuis

Universidade de Franche-Comté

17 PUBLICAÇÕES 82 CITAÇÕES

VER PERFIL



Christophe Guyeux

Universidade de Franche-Comté

296 PUBLICAÇÕES 2.772 CITAÇÕES

VER PERFIL



Guillaume Royer

SDIS 25

9 PUBLICAÇÕES 91 CITAÇÕES

VER PERFIL

Alguns dos autores desta publicação também estão trabalhando nos seguintes projetos relacionados:



Estimativa de tensor de posto baixo [Ver projeto](#)



Implementação de hardware de geradores de números aleatórios baseados em iteração caótica e generalizada (CIRNG/GIRNG) no projeto ZYNQ/ASIC [View](#)

Artigo

Preveno avarias operacionais de brigadas de incêndio: Um estudo de caso real

Selene Cerna ^{1,*}, Christophe Guyeux ¹, Guillaume Royer ², Céline Chevallier & Guillaume Plumerel ²

¹ Instituto Femto-ST, Universidade de Bourgogne Franche-Comté, UBFC, CNRS, 90000 Belfort, França; christophe.guyeux@univ-fcomte.fr SDIS25—Service Départemental d'Incendie et de Secours du Doubs, 25000

² Besançon, França; guillaume.royer@sdis25.fr (GR); celine.chevallier@sdis25.fr (CC); guillaume.plumerel@sdis25.fr (GP)

* Correspondência: selene_leya.cerna_nahuis@univ-fcomte.fr

Recebido: 3 de julho de 2020; Aceito: 11 de agosto de 2020; Publicado: 18 de agosto de 2020



Resumo: Ao longo dos anos, os corpos de bombeiros têm buscado métodos para identificar suas interrupções operacionais e estabelecer estratégias que lhes permitam organizar eficientemente seus recursos. O presente trabalho desenvolve uma metodologia para cálculo de quebras e outra para previsão de interrupções com base em técnicas de aprendizado de máquina. O objetivo principal é estabelecer indicadores para identificar as falhas devido ao estado temporal da organização no material humano e veicular. Da mesma forma, ao prever interrupções, determinar estratégias para a implantação ou aquisição do armamento necessário. Isso permitiria melhorar a resiliência operacional e aumentar a eficiência dos bombeiros ao longo do tempo. A metodologia foi aplicada ao Departamental Fire and Rescue Doubs (SDIS25) na França. No entanto, é genérico o suficiente para ser estendido e adaptado a outros corpos de bombeiros. Considerando um histórico de quebras de 2017 e 2018, as melhores previsões de quebras do serviço público para o ano de 2019 apresentaram uma raiz quadrada média de erro de 2,5602 e um erro médio absoluto de 2,0240 em média com a técnica XGBoost.

Palavras-chave: quebras operacionais; previsão de interrupções; bombeiros; cálculo de quebra; XGBoostGenericName

1. Introdução

Em todo o mundo, diversos corpos de bombeiros sofrem as consequências de manter um orçamento reduzido ou constante diante do crescimento linear de sua carga de trabalho ao longo dos anos. Além disso, sob certas condições (como diante de uma pandemia), o crescimento pode ser exponencial. Por isso, é necessário analisar as variáveis que devem ser consideradas para a reorganização dos recursos humanos, materiais e financeiros. Começar pelo estabelecimento de indicadores que permitam identificar o estado atual e acompanhar o processo de melhoria, consequentemente, leva a melhores decisões na gestão do orçamento e das necessidades operacionais.

Um bom ponto de partida é a previsão de intervenções [1–3]. Conhecer os possíveis acidentes futuros que os bombeiros atenderão ajudaria a estimar a carga de trabalho que eles teriam em um determinado horizonte de tempo futuro. Permitiria conhecer as futuras áreas ou populações em risco. Forneceria também estatísticas sobre instalações de cuidados com um aumento na demanda. Além disso, ajudaria a estabelecer razoavelmente novas estratégias, ou seja, alocação de material humano e técnico, para evitar interrupções no serviço. Ou, na pior das hipóteses, para recuperar rapidamente a estabilidade operacional.

No entanto, os bombeiros têm uma grande responsabilidade, que é a segurança pública, e um estudo técnico sobre detecção e previsão de falhas no corpo de bombeiros ajudaria a determinar a eficiência e resiliência operacional futura e atual. Por meio de indicadores de desempenho, gerados ao desenvolver uma estratégia de cálculo de pane, seria possível descobrir a falta de motores, a falta de

bombeiros e a falta de habilidade que os bombeiros devem ter para manusear um determinado motor, ou seja, conhecer o estado técnico atual de um centro de serviço e, juntamente com a previsão de avarias usando técnicas de aprendizado de máquina, poderiam ser obtidas estatísticas sobre os centros que serão relativamente ineficientes ou que terão problemas na disponibilidade de recursos no futuro. Portanto, estabeleça um orçamento necessário para aquisição de novos materiais e alocação de recursos de acordo com a necessidade do corpo de bombeiros ou de cada filial (central de atendimento).

O presente trabalho é um estudo de caso realizado com o apoio do Corpo de Bombeiros e Resgate de Doubs (SDIS 25), França. O objetivo é estabelecer um processo para identificar as interrupções dos anos de 2017, 2018 e 2019, calcular seus tipos e horários em cada centro de assistência e determinar a disponibilidade de recursos em um determinado momento. Além disso, desenvolver um modelo matemático que permita uma busca ótima por um motor adaptado disponível em um centro e horário específicos. Além disso, finalmente, prever as quebras para os meses de 2019 usando técnicas de aprendizado de máquina. Esta metodologia poderia ser aplicada a outros corpos de bombeiros, dependendo dos seus dados, o que ajudaria a melhorar a qualidade do serviço prestado.

O presente trabalho está estruturado da seguinte forma: a Seção 2 faz uma breve descrição das contribuições dos trabalhos relacionados, a Seção 3.1 descreve o processo de cálculo da desagregação, detalhando os dados utilizados, o fluxograma do processo e o modelo criado para otimizar a busca por armamento adaptado. A seção 3.2 expõe o pré-processamento dos dados realizado para as quebras operacionais, ou seja, a coleta dos dados, sua padronização e a divisão dos dados a serem treinados e testados. Além disso, é detalhada uma breve descrição das técnicas utilizadas para previsão e a otimização bayesiana aplicada para encontrar os melhores hiperparâmetros de cada modelo. A Seção 4 apresenta os resultados e discussões sobre o cálculo das avarias, bem como sobre as previsões obtidas e seus modelos. Por fim, a Seção 5 apresenta nossas conclusões. A Tabela 1 apresenta as abreviaturas e as siglas que serão utilizadas no presente trabalho.

Tabela 1. Lista de abreviaturas e siglas utilizadas no presente trabalho.

Categoria	Abreviação/Sigla	Definição
Métricas de análise	Nb	Número de avarias
	Padrão	Desvio padrão
Motores	AE	motor adaptado
	NAE	Motor Não Adaptado
Motor para RP	RVAV	Veículo de Resgate e Assistência a Vítimas
Métricas de avaliação	MAE	Erro Absoluto Médio
	RMSE	Raiz do erro quadrático médio
arquivos	DP	Plano de preparação
habilidades de bombeiro	CG	chefe da guarda
	CM	membro da tripulação
	RD	Condutor
	TL	Lider do Time

Tabela 1. Cont.

Categoria	Abreviação/Sigla	Definição
Técnicas de modelagem	<small>AdaBoostGenericName</small> Adão	Adaptive Boosting
	BO	Estimativa de Momento Adaptativo
	BRR	Otimização bayesiana
	DEA	Regressão Bayesiana Ridge
	DSM	Análise Envoltória de Dados
	GESA	Modelo Padrão Duplo
	MLP	Abordagem de escala de eficiência de número de grupo
	ReLU	Perceptron Multicamadas
	RF	Unidade Linear Retificada
	SVM	floresta aleatória
	UCB	Máquina de vetores de suporte
Tipos de intervenções	<small>XGBoostGenericName</small> FR	Limite Superior de Confiança
	PR	Aumento de Gradiente Extremo
		Fogo
zonas	Z1	resgatar pessoas
	Z2	Zona 1, Urbana
	Z3	Zona 2, Semi-urbana
		Zona 3, Rural

2. Trabalho relacionado

Tanto quanto é do conhecimento do autor, não existem trabalhos de investigação sobre a tarefa específica de detecção de avarias e sua previsão no serviço de bombeiros. Por outro lado, encontramos trabalhos relacionados como [4], onde o serviço de eficiência futura, do Corpo de Bombeiros do Condado de Tainan em Taiwan, foi analisado e aprimorado alocando recursos de acordo com as tendências futuras de produção. Para isso, foram utilizadas as técnicas Data Envelopment Analysis (DEA) e Group-number Efficiency Scale Approach (GESA) com variáveis de entrada como número de plantões, custo de plantão, número de carros de bombeiros e taxa de manutenção do veículo. Em 2020, Morello et al. [5] desenvolveram sete modelos econométricos para previsão de incêndios na Amazônia brasileira com o objetivo de estabelecer políticas de supressão de incêndios florestais. Quatro dos modelos com o menor RMSE obtiveram um erro percentual não superior a 29%. Da mesma forma, o estudo revelou que as mudanças espaciais e temporais dos incêndios foram influenciadas por fatores econômicos, institucionais, climáticos e físicos, ou seja, áreas desmatadas, áreas protegidas, florestas degradadas, PIB, temperatura, precipitação, qualidade do solo, entre outros.

Da mesma forma, para o caso de aumento da procura de ambulâncias, onde a literatura é mais extensa, pode-se encontrar [6], onde é proposta uma ferramenta que, através de simulações de respostas a incêndios e emergências, otimiza a localização das viaturas e o seu envio para uma emergência. Em 2016, Dibene et al. [7] desenvolveram uma modificação para o Modelo Padrão Duplo (DSM) aplicado ao problema de localização de ambulâncias da Cruz Vermelha de Tijuana, México, utilizando programação linear inteira. Em 2019 [8], utilizando dados do Serviço de Emergência Médica de Lisboa, Portugal, foi apresentado um modelo matemático que integra as decisões de despacho e realocação com um método heurístico aplicado durante o processo de realocação, onde o objetivo principal é maximizar a cobertura da implantação. Em [9], modelos com diferentes técnicas de aprendizado de máquina foram construídos para prever a demanda diária de ambulâncias em Cingapura. O conjunto de dados continha ambulância real e dados demográficos de 2006 a 2016. Os autores afirmaram que as características mais importantes foram a demanda total nos últimos 30 dias e 7 dias, e os melhores resultados foram obtidos com a técnica LightGBM.

Além disso, trabalhos como [10,11] propõem abordagens para alocação ótima de recursos diante de desastres. A primeira desenvolve um modelo gráfico para a área de estudo, onde cada nó representa uma série de recursos localizados, e um modelo matemático que descreve a região e a dinâmica dos incêndios detectados. Os autores concluem que a estratégia de alocação de recursos em tempo real permite uma maior diminuição da área queimada em comparação com uma estratégia heurística gulosa, onde os recursos são alocados

quando o fogo mais próximo tiver sido completamente extinto. Além disso, o segundo artigo propõe um modelo de programação estocástica inteira, considerando diferentes cenários de incêndios florestais com o objetivo de minimizar o custo produzido pela supressão do incêndio, as áreas danificadas e o número de pessoas em risco. No entanto, o modelo faz suposições que na vida real seriam mais complexas de implementar. Além disso, nosso grupo de pesquisa desenvolveu uma metodologia de predição de intervenções usando Long-Short Term Memory (LSTM) [12], onde variáveis internas, como datas e número de incidentes ocorridos, e variáveis externas, como clima, trânsito, feriados, entre outras, foram incluídos.

Além disso, os dados foram normalizados, as características foram selecionadas usando Mutual Information (MI) e um algoritmo genético foi usado para a seleção do modelo. Os resultados mostraram uma precisão de 55,41% com margem de erro menor ou igual a um. Na busca por uma melhor previsão dos incidentes, foram comparados os desempenhos de LSTM e Extreme Gradient Boosting (XGBoost) [1], mais variáveis externas foram adicionadas para o reconhecimento de padrões, atingindo uma precisão de 76,94% com uma margem de erro de ± 2 incidentes usando a técnica XGBoost. Durante a análise dos dados ao longo dos anos, descobriu-se um aumento quase linear nas intervenções, o que mostra o aumento da carga de trabalho e sugere que sob um orçamento constante poderia ocorrer mais quebras no serviço. Para aprofundar a pesquisa, comparações foram feitas com XGBoost, Adaptive Boosting (AdaBoost) e Gradient Boosting [13], pois essas técnicas têm se mostrado muito eficazes na modelagem de alto comportamento não linear. Além disso, foram estudadas várias formas de construir uma rede neural Multilayer Perceptron (MLP) para prever intervenções [3], levando em consideração hiperparâmetros como o número de camadas e seu número correspondente de neurônios, o otimizador e a função de ativação. Além disso, as técnicas de anonimização também foram testadas. Em [2] as intervenções com as vítimas foram anonimizadas por meio de técnicas de k-anonimato e Privacidade Diferencial, a fim de prever as intervenções diárias em número e tipo para as duas grandes cidades da região em estudo. Os autores concluíram que a confidencialidade diferencial produziu resultados mais precisos. Além disso, em [14], os autores propuseram uma metodologia para coletar de forma privada o número de intervenções dos bombeiros por local. A técnica empregada permitiu estimar o número de intervenções por região para cada dia respeitando a privacidade.

A última estimativa (dados sintéticos) foi então usada para prever o número de intervenções por região usando o XGBoost. Foi mostrado que o uso de dados anônimos ainda pode garantir boas estimativas em comparação com o conjunto de dados brutos.

3. Metodologia

Esta seção define a metodologia aplicada para o cálculo da quebra. O resultado em conjunto com outras variáveis explicativas, que serão descritas na subseção Previsão de quebras, servirá de insumo para a previsão de interrupções operacionais do SDIS25 nos 12 meses do ano de 2019.

3.1. O processo de cálculo de quebra

A desagregação operacional é definida pelo SDIS25, tendo em conta a carga operacional momentânea de um setor (e eventualmente dos setores vizinhos), como a incapacidade de prestar assistência nos prazos de cumprimento dos objetivos definidos. Nas subseções seguintes, o processo de cálculo da repartição é descrito em detalhes.

3.1.1. Visão geral

As informações fornecidas pelo SDIS25 para o cálculo da quebra são dos anos de 2017 a 2019. Numa primeira análise, os tipos de intervenção analisados foram Socorristas (RP) e Bombeiros (FR). A Figura 1 mostra o processo de cálculo de ruptura que é composto por 3 etapas:

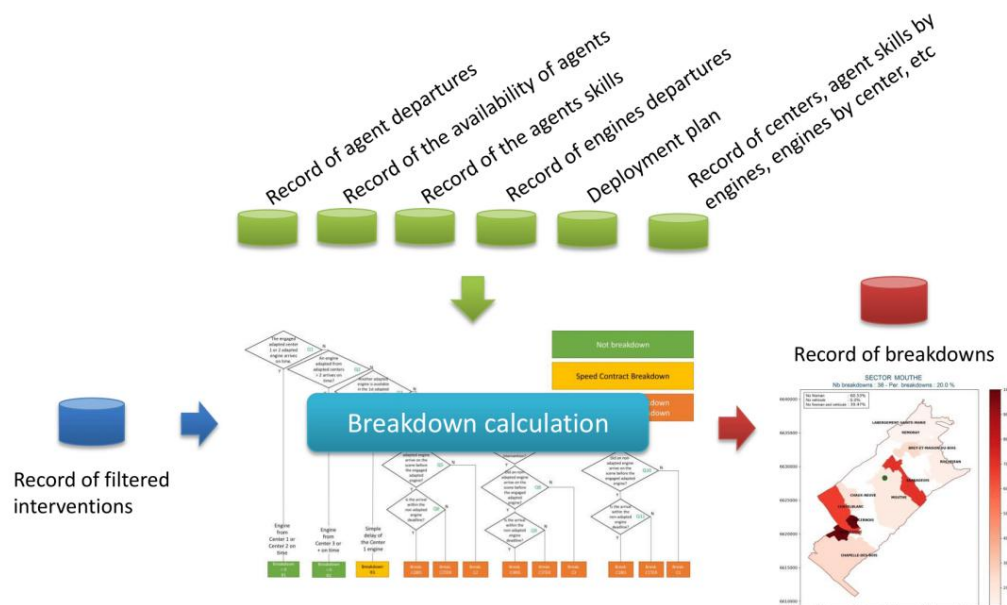


Figura 1. Visão geral do cálculo de quebra. Em azul, mostra as intervenções que serão processadas; em verde, os registros históricos das variáveis geográficas e administrativas; e em vermelho, as intervenções que resultaram em quebras.

• Estágio 1:

- a Identificar todas as intervenções ocorridas na região de Doubs pelo corpo de bombeiros SDIS25. Isso porque há intervenções que aconteceram fora da região em auxílio de outros corpos de bombeiros.
- b Determine sua localização para reconhecer as 3 áreas principais definidas pelo SDIS25, a saber: zona 1 (Z1), zona 2 (Z2) e zona 3 (Z3). Essas zonas determinam o tempo limite que um Motor Adaptado (AE) e um Motor Não Adaptado (NAE) levam para chegar ao local. A relação entre as cidades da região e as zonas tem por base o Plano de Desdobramento (DP) desenhado pelo corpo de bombeiros para um fácil reconhecimento dos centros que terão de responder a uma emergência naquela zona.
- c Finalmente, obtemos uma lista filtrada das intervenções que entrarão na próxima etapa.

• Estágio 2:

- a As intervenções entram no cálculo da avaria, mas primeiro é validado se estão presentes todas as informações necessárias, tais como: início e fim da intervenção, motor utilizado, bombeiros participantes, horários de saída e regresso.
- b Em conjunto com outros dados como o histórico das saídas dos bombeiros e viaturas, dados administrativos como os tempos de disponibilidade dos bombeiros profissionais e voluntários, bem como as suas competências e o DP que permite identificar os primeiros centros a responder a incidentes, são usados durante o cálculo.
- c Finalmente, todas as intervenções processadas são obtidas.

- Etapa 3: Os resultados fornecem estatísticas sobre a capacidade de resposta das agências do SDIS25, que são preferencialmente apresentadas em mapas por setor, sendo setor a área de abrangência de um posto de atendimento. Estes serão descritos com mais detalhes na Seção 4.1.

O processo permite conhecer o estado técnico atual de cada filial e do SDIS25 em geral. Assim, os setores que apresentam mais rupturas podem ser visualizados para atuar na gestão de seus recursos. Se, por exemplo, os recursos de um centro temporariamente ineficiente fossem reduzidos, isso traria sérias consequências para a segurança pública em um determinado momento.

3.1.2. Fontes de dados

Uma parte essencial do cálculo de detalhamento é ter os dados necessários para obter estatísticas mais detalhadas. Ao mesmo tempo, permite conhecer o ambiente, ou seja, a capacidade de recursos humanos e materiais que cada centro possui, e como é ou seria afetado com o aumento ou diminuição de recursos numa futura otimização. Assim, poderíamos fornecer recursos suficientes para um ramo afetado e aumentar a eficiência de sua capacidade de resgate e socorro.

O conjunto de dados considera:

Geograficamente:

- a As coordenadas do local das intervenções. b As coordenadas da localização dos centros. c Arquivos shape das geometrias de cada cidade do departamento de Doubs. Uma cidade contém 0 ou mais distritos. No total, foram contabilizados 573 municípios e 440 distritos.
- d Plano de implantação que fornece uma relação das cidades e seus distritos na região. Cada cidade e distrito tem uma zona atribuída (Z1, Z2 e Z3). A zona fornece os limites de tempo que um centro e seus motores têm para chegar ao local. Esses prazos dependem do tipo de motor AE ou NAE. Os prazos para ambos os tipos de intervenção são os mesmos e estão descritos na Tabela 2. Um NAE em Z1 tem 10 min para chegar ao local e 20 min em Z2 e Z3. No entanto, o tempo para um EA depende se um NAE chegou primeiro ao local. Por exemplo, em Z2, o AE tem 25 min para chegar ao local se já existiu um NAE antes dele, caso contrário o seu tempo é reduzido para 20 min.

Administrativamente:

- a Registros das intervenções. Contêm um identificador, o início, a chegada ao local da primeiro motor adaptado e final da intervenção.
- b Registros de partidas de motores. Contêm o identificador e o tipo de intervenção, o centro de assistência, a matrícula do motor, o tipo de motor, a data e hora em que o motor recebe o alerta de intervenção, a partida do motor, a chegada ao local, a partida para o hospital e o fim de sua missão. c Registros de saídas de agentes. Contêm as mesmas características dos registros descritos acima, incluindo o identificador e o nome completo do agente.
- d Registros da agenda de disponibilidade dos agentes.
- e Registros das habilidades dos agentes obtidos ao longo dos anos para operar um motor, dependendo se o agente é profissional ou voluntário. f Registros dos centros que incluem o número e a quantidade de motores que possuem.

3.1.3. Diagrama do Processo de Cálculo

Para processar as intervenções e saber se ocorreram rupturas, foi desenvolvido um algoritmo baseado no fluxograma da Figura 2.

Diz-se que um motor adaptado está disponível quando tem o número de agentes necessários para partir. Os agentes devem ter certas habilidades para lidar com o motor. As habilidades dependem do tipo de intervenção e do motor selecionado. A título ilustrativo as competências mais representativas são: Piloto (DR), Chefe de Guarda (CG), Chefe de Equipa (TL) e Tripulante (CM). Para uma intervenção de RP, as habilidades necessárias são DR, CG e CM. Além disso, para uma intervenção FR, são: DR, CG, TL e CM.

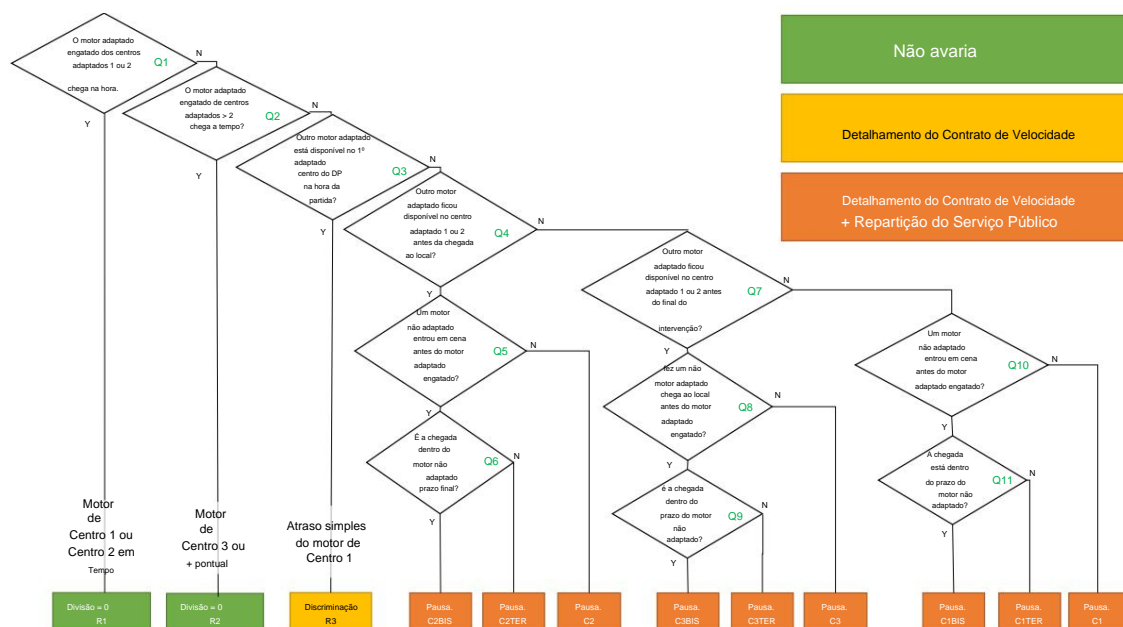


Figura 2. Cálculo do breakdown. Ele mostra o processo pelo qual o nível de quebra de uma intervenção é calculado, onde as respostas em cada nível podem ser S = sim, N = não.

São vários os tipos de centrais que o SDIS25 comanda em Doubs. Para nossa análise, consideramos apenas centros adaptados. Um centro ou sucursal está adaptado quando possui motores adaptados aos tipos de intervenção analisados. Daqui em diante usaremos a palavra centro para nos referirmos a um centro adaptado.

Existem dois tipos de avarias: Avaria do Contrato de Velocidade, é quando a locomotiva e os agentes chegam ao local fora dos prazos definidos no Quadro 2, por motivos internos (pode ser devido a um atraso na partida) ou motivos externos (podem ser devido ao congestionamento de veículos no percurso); e Ruptura do Serviço Público, é quando os centros não possuem recursos suficientes no momento de uma intervenção para cobrir uma intervenção posterior.

Tabela 2. Limite de atraso de tempo definido para um NAE e um AE de acordo com a área alvo.

Motor Não Adaptado à Zona	motor adaptado		
	Sem Motor Não Adaptado		Com Motor Não Adaptado
Z1	10	10	10
Z2	20	20	25
Z3	20	20	25

As intervenções são classificadas como R1 e R2 quando não houve desmembramento. Além disso, como R3 quando havia um motor adaptado disponível na reserva, mas a equipe envolvida na atual intervenção chegou atrasada ao local.

Os dois tipos de ruptura podem ocorrer ao mesmo tempo, e são classificados em nove casos. Os casos C2BIS, C2TER e C2 ocorrem quando não havia outro motor adaptado disponível no primeiro ou segundo centro entre a saída e a chegada ao local. Isso indica que faltou motor ou agentes disponíveis para uma intervenção posterior. A subclassificação é dada respondendo às questões se houve ou não um NAE antes do EA e se ambos chegaram dentro dos prazos definidos. Os casos C3BIS, C3TER e C3 são produzidos porque não havia motor adaptado disponível entre a chegada ao local e antes do final da intervenção. A subclassificação é conforme descrito anteriormente. Os casos C1BIS, C1TER e C1 são os piores cenários, pois indicam que até o final de uma intervenção que pode durar em média quase 2 h, não houve

recursos disponíveis no primeiro ou segundo centro para garantir a segurança e o bem-estar da população de uma determinada localidade.

Para cada caso de quebra no fluxograma, foi projetado um cálculo do tempo de quebra.

Para uma ilustração mais simplificada, descreveremos a ideia geral da seguinte forma:

a Os dados necessários para calcular o tempo de avaria são: a hora em que o alerta é recebido, a hora das chegadas do AE e NAE ao local e a hora em que o centro 1 ou 2 tem um AE disponível.

b Diante de uma intervenção, há quebra do contrato de velocidade quando o AE ou NAE engajado ultrapassa o tempo limite de chegada à área, descrito na Tabela 2. Portanto, a diferença entre esses dois é o tempo de quebra. c Dada uma intervenção, o tempo de interrupção do serviço público é o período em que um centro não dispõe de recursos de reserva. O tempo de avaria é a diferença entre a hora a que uma central recebe o alerta para comparecer à intervenção mais o tempo limite estabelecido na Tabela 2 para o AE acionado com ou sem NAE e a hora a que a central volta a ter um AE disponível.

De fato, o resultado desse processo fornece informações detalhadas sobre as cidades e distritos onde ocorreram mais avarias, áreas que podem ser de difícil acesso e que podem exigir um centro mais próximo ou encontrar a melhor rota para chegar. Também nos fornece estatísticas por tipo de intervenção, o que nos permite reconhecer a falta de um material específico. Ele gera estatísticas sobre o primeiro call center que estava parcialmente sem recursos e o segundo call center que não conseguiu cobrir o primeiro call center. Fornece informações sobre a falta de um motor específico ou bombeiro e suas habilidades. Em resumo, isso nos permite analisar e determinar os problemas com os quais o centro lida. Consequentemente, permitiria otimizar a distribuição de recursos de forma mais precisa e aumentar a capacidade operacional dos centros de acordo com a necessidade.

3.1.4. Otimização de pesquisa para agentes e mecanismos disponíveis

Durante o cálculo das ruturas de serviço público, em cada intervenção processada, teve de ser validado e recuperado um motor adaptado disponível no centro 1 ou no centro 2 num determinado período de tempo. Conforme explicado na seção anterior, para montar o equipamento e garantir a disponibilidade do centro, um motor adaptado deve estar disponível com os agentes e suas respectivas habilidades para operar o motor. Realizar uma busca deste porte entre milhares de bombeiros e diversas perícias que se enquadram em diversos tipos de EAs requer um grande consumo de recursos e tempo, pois teríamos que tentar muitas combinações até encontrar uma viável.

Por este motivo, foi necessário modelar um método para otimização de busca. O modelo criado foi construído com a biblioteca GEKKO do Python [15], utilizando o solver Mixed Integer Nonlinear Programming. É descrito da seguinte forma:

$$\begin{aligned} \min & 0, \\ \text{st} & A_{ij}x_j \leq b_i, \\ & A_{ij}, x_j \in \{0, 1\}, b_i \geq 0 \end{aligned} \quad (1)$$

onde: A_{ij} é uma matriz booleana que representa a capacidade i que possui um agente j disponível, x_j é um vetor booleano que representa se um agente j foi selecionado (assume valor 1) ou não (assume valor 0) para partir em missão com um AE específico, b_i representa o número mínimo de agentes necessários por habilidade para o AE partir em missão.

Observe que o objetivo não é minimizar uma função objetivo, mas encontrar rapidamente uma solução viável que sabemos existir após ter definido previamente as restrições para entrar no processo, ou seja, estabelecemos o solucionador de restrições para calcular uma solução arbitrária dentro do espaço de soluções viáveis e não como um mecanismo de otimização. Portanto, a função objetivo é apenas uma constante (zero) independentemente da solução.

Dado um motor adaptado e sabendo que um agente pode ter várias habilidades ao mesmo tempo, algumas das principais restrições foram: o número de agentes disponíveis deve ser maior ou igual ao número mínimo de agentes necessários para partir. Pelo menos um dos agentes disponíveis deve ter a capacidade de ser um motorista (DR) para um determinado AE. As habilidades encontradas nos agentes disponíveis devem cobrir as habilidades necessárias. Para uma visão mais clara do modelo, um exemplo é mostrado a seguir:

Imaginemos que uma intervenção é do tipo RP, estão neste momento 10 bombeiros disponíveis e é necessário montar o equipamento para um motor adaptado: Veículo de Socorro e Socorro à Vítima (RVAV). Este mecanismo precisa de 3 agentes: pelo menos 1 agente com a habilidade DR, pelo menos 1 agente com a habilidade CG e pelo menos 1 agente com a habilidade CM. Então, o sistema seria:

$$\begin{array}{cccccccc}
 & 0 & 1 & 0 & 1 & 0 & 1 & 0 & 0 & 1 & 0 \\
 \vec{y} & 0 & 0 & 1 & 1 & 0 & 0 & 1 & 0 & 1 & 0 \\
 \vec{y} & 0 & 1 & 1 & 1 & 0 & 1 & 1 & 0 & 1 & 0
 \end{array}
 \quad
 \begin{array}{ccc}
 \vec{y} & \begin{matrix} x1 \\ x2 \\ \vdots \\ x10 \end{matrix} & \vec{y} \\
 \vec{y} & \begin{matrix} 1 \\ 1 \\ \vdots \\ 1 \end{matrix} & \vec{y}
 \end{array}
 \quad (2)$$

Cada linha da matriz booleana corresponde a uma habilidade (DR, CG e CM) e cada coluna representa um agente disponível. Juntos, eles simbolizam as habilidades por agente. A coluna do vetor x representa os bombeiros ou agentes que serão escolhidos e o vetor do lado direito mostra a quantidade de agentes necessários por perícia.

Isso nos permite reconstruir um armamento em um tempo específico e garantir a disponibilidade de um adaptado recurso de reserva para o caso de uma nova emergência.

3.2. Prevendo quebras

As perturbações calculadas até agora permitem examinar o estado atual de eficiência de cada centro de acordo com seus recursos. De forma mais geral, eles nos permitem conhecer os desdobramentos do SDIS25 e suas tendências nos últimos 3 anos na região de Doubs. Da mesma forma, se prevermos as rupturas para os próximos meses, teremos uma visão mais ampla do que enfrentarão caso não haja aquisição ou reorganização dos recursos atuais, de forma a proteger o bem-estar da população. Assim, com base em técnicas de Machine Learning e em conjunto com outras variáveis internas e externas, será possível prever as quebras para os próximos meses.

O conjunto de testes são os 12 meses do ano de 2019 e o conjunto de treinamento iniciará com os anos de 2017 e 2018, e de acordo com o mês previsto o conjunto de treinamento aumentará.

Além disso, as avarias são agrupadas por dia. Embora o conjunto de dados seja pequeno no momento, as previsões feitas são uma primeira abordagem antes de continuar com a otimização de recursos por centro, que está além do escopo deste artigo e é um trabalho futuro. Além disso, o presente trabalho desenvolve previsões para disrupções do tipo: Serviço Público. Esse tipo de rompimento é um indicador para o reconhecimento da falta de material técnico, ou seja, falta de motores e agentes capacitados em determinado período.

As previsões serão o número total de avarias do serviço público que o SDIS25 terá para cada mês de 2019.

3.2.1. Pré-processamento de dados

Para preencher nosso conjunto de dados, extrair mais características das variáveis explicativas e normalizá-las para auxiliar na convergência, realizamos o pré-processamento dos dados.

Os dados coletados cobrem variáveis internas como: número de motores disponíveis por dia, número de bombeiros que trabalharam em um determinado dia e avarias ocorridas na região de Doubs.

Em artigos anteriores [3,13,14], vários modelos foram construídos para a previsão de intervenções.

Portanto, se conhecermos as intervenções futuras com uma precisão razoável, estas podem ser usadas como dados de entrada para a previsão de avarias. Em nossos testes, o número de intervenções por dia é incluído no conjunto de dados como uma variável explicativa.

Além disso, foram adicionadas variáveis externas como: dados meteorológicos (temperatura, pressão, tendência barométrica, umidade, ponto de orvalho, precipitação, velocidade do vento, direção do vento, velocidade das rajadas e tipo de clima) de Météo-France [16], obtidos a cada 3h; estatísticas epidemiológicas sobre diarreia, gripe e varicela da rede Sentinelles [17], obtidas semanalmente; a previsão do nível de tráfego para cada dia de Bison-Futé [18], previsto por ano; e a distância entre o planeta Terra e a Lua para analisar possíveis correlações (por exemplo, entre erupções solares e incêndios devido a incidentes elétricos), obtidos por dia de Skyfield [19]. Além disso, foram incluídas variáveis de tempo como: dia, dia do ano, dia da semana, mês e ano; e indicadores de tempo como fim de semana, início e fim do mês, início e fim do ano.

Dados numéricos como variáveis meteorológicas, exceto tendência barométrica e tipo de clima, dados epidemiológicos, distância à lua, dia, dia da semana, dia do ano, mês e ano foram padronizados com o método RobustScaler da biblioteca Scikit-Learn em Python [20], onde os dados são centralizados antes do dimensionamento. Dados categóricos como indicadores de tráfego, tendência barométrica e tipo de clima foram codificados usando o método One-Hot-Encode, também do Scikit-Learn. Por fim, a variável alvo não foi codificada, pois melhores resultados foram obtidos sem a sua codificação.

As quebras foram agrupadas por dia, assim como todas as outras variáveis. Aquelas variáveis numéricas coletadas por hora foram calculadas a média ao longo de um dia, e a partir das categóricas sua moda foi calculada. As desagregações dos anos de 2017 e 2018, 730 amostras no total, foram utilizadas durante o treinamento para prever o mês de janeiro de 2019; os detalhamentos de 2017–2018 e janeiro de 2019 foram usados para prever fevereiro de 2019, e assim por diante, ou seja, um modelo é gerado para cada mês do ano de 2019.

3.2.2. Modelagem com Técnicas de Machine Learning

O modelo de linha de base foi construído calculando a média diária de quebras de serviço público em cada mês para os anos de 2017 e 2018. Além disso, outros modelos foram desenvolvidos com as técnicas:

um Extreme Gradient Boosting (XGBoost), reconhecido por sua alta capacidade de processamento paralelo e robustez. Além disso, sua função objetivo considera a função perda e também um regulador para minimizar a complexidade do modelo [21]. b Multilayer Perceptron (MLP), retirado da implementação feita na biblioteca Scikit-Learn. É uma rede neural artificial feedforward [22], constituída por um conjunto de unidades, denominadas neurônios, organizadas em camadas de entrada, ocultas ou intermediárias, e de saída que são interligadas. Os neurônios são ativados por uma função de ativação como a Unidade Linear Retificada (ReLU), que será utilizada em nossos modelos. A informação é aprendida através de um algoritmo de otimização como o Adaptive Moment Estimation (Adam) [23], também utilizado no presente trabalho.

c Bayesian Ridge Regression (BRR), da biblioteca Scikit-Learn. Estima um modelo probabilístico linear. É principalmente regularizado pelos parâmetros λ e α , que são a precisão dos pesos e ruído respectivamente [24,25]. d Support Vector Machine (SVM), retirado da biblioteca Scikit-Learn. Seu principal objetivo é encontrar um hiperplano que melhor divida um conjunto de dados em classes. Também é aplicado a problemas de regressão, usando, por exemplo, o método Epsilon-Support Vector Regression [26]. e Random Forest (RF), da biblioteca Scikit-Learn. Este é um método de aprendizado por conjunto, que gera aleatoriamente várias árvores de decisão em paralelo com subconjuntos das amostras. Um conjunto de árvores forma uma floresta aleatória. No caso da regressão, o resultado é dado pela média das árvores individuais [27].

Como uma grande variedade de configurações de hiperparâmetros é apresentada em cada técnica, optamos pela Otimização Bayesiana (BO) para guiar o aprendizado de nossos modelos [28]. A otimização bayesiana permite a otimização geral das funções de caixa preta. Conforme descrito em [29], o BO cria um modelo substituto probabilístico, ou seja, existe uma distribuição preliminar que descreve como aparentemente está o comportamento da função objetivo desconhecida, isso permite criar um modelo que descreve o

geração de dados. O modelo seleciona a seguinte configuração que maximiza a função de aquisição. A função de aquisição permite a exploração e exploração do espaço de busca e é mais barata de avaliar do que a função de caixa preta. No presente trabalho, a biblioteca [30] foi utilizada para a Otimização Bayesiana.

4. Resultados e discussão

4.1. Resultados e Discussão do Cálculo de Breakdowns

As Figuras 3 e 4 apresentam o número de interrupções de contrato de velocidade e de serviço público respectivamente para cada mês dos 3 anos. A Tabela 3 descreve a informação estatística das avarias do serviço público ao longo dos 3 anos, onde Nb é o número de perturbações, Mean é a média das perturbações e Std é o desvio padrão. A Figura 5 apresenta as causas das rupturas do serviço público para cada mês de 2019. As Figuras 6 e 7 mostram o mapa de Doubs e as interrupções do serviço público Rescue People e Fire, respectivamente, por setor de cada centro adaptado para 2019.

Como pode ser observado nas Figuras 3 e 4, ambas apresentam um aumento das rupturas ao longo dos anos. O número de avarias no contrato de velocidade atinge um pico em torno de 700, enquanto as avarias no serviço público chegam a cerca de 300, ambos no ano de 2019. Maio, junho, julho e agosto são os meses com mais rupturas, principalmente julho; isso se deve ao fato de que neste mês são feriados na região e há menos agentes nos centros. Além disso, estar em férias também predispõe a mais intervenções, pois estão intimamente relacionadas à atividade humana, como acidentes de trânsito ou afogamentos em piscinas.




Figura 3. Divisões de contratos de velocidade 2017–2019.

No entanto, daremos prioridade à análise das rupturas do serviço público neste estudo, pois permite examinar melhor as falhas de recursos no corpo de bombeiros. Na Tabela 3, pode-se observar que o maior número de interrupções ocorreu em julho de 2019, seguido de julho de 2018 e dezembro de 2017. Além disso, há um incremento na média diária de interrupções do serviço público no mês de julho de 5 para 9,83, quase o dobro. Embora o número de intervenções (filtradas) realizadas em julho tenha sido de 2.525, 2.883 e 2.193 para 2017, 2018 e 2019, respectivamente, e suas médias diárias foram: 81,45, 93 e 70,74 para os 3 anos na mesma ordem e respectivamente, isso mostra que em julho de 2019 houve menos intervenções, mas mais rupturas. Pode-se deduzir a necessidade de prever intervenções e rupturas em um determinado horizonte de tempo, a fim de estabelecer estratégias de reorganização dos recursos.

O fluxograma utilizado para o cálculo das avarias também permite identificar as causas das avarias do serviço público, pois ao responder “Não, não existe motor adaptado disponível”, aprofundamos e qualificamos consoante a disponibilidade, se era devido à falta de mecanismo, agentes ou ambos. Além disso, se foi por falta de agentes, examina-se que tipo de habilidade faltou, o resultado

é mostrado na Figura 5. Aqui, continuando com o mês de julho, mais de 100 interrupções observadas foram devidas apenas à ausência de agentes e aproximadamente 80 devido à falta de veículos e agentes ao mesmo tempo. A maioria das quebras que não apresentaram agentes se deve à ausência da habilidade DR e em menor grau da habilidade TL. Por outro lado, os meses de janeiro e junho também apresentam um elevado número de avarias, no entanto a causa deve-se à insuficiência de motores disponíveis.




Figura 4. Avarias no serviço público 2017–2019.

Tabela 3. Informação estatística das desagregações do serviço público por mês de 2017 a 2019.

Mês	2017				2018				2019			
	Nb	Média	Std	Nb	Média	Std	Nb	Média	Std	Nb	Média	Std
JANEIRO	166	5.3548	2.9789	219	7.0645	4.0475	213	6.8710	3.1082	Fevereiro	117	4.1786
	158	2.7299	5.4643	111	2.5282	3.5806	188	1.9472	6.0645	3.6456	4564564564564564564506450,60610,5.45.645.5.5.5.5.5282	
Marchar	111	3.5806	1.9472	188	6.0645	3.5064	5645645645645645.6456456450,5.5.5.5.5.5.5282.					
abril	103	3.4333	1.9610	140	4.6667	2.4267	193	6.4333	2.7530			
Poderia	131	4.2258	2.4978	195	6.2903	2.5927	199	6.4194	3.7996			
Junho	122	4.0667	2,3228	189	6,3000	3,2470	248	8,2667	4,0819			
Julho	155	5,0000	2,9621	241	7,7742	3,8497	305	9,8387	3,3029			
August	125	4.0323	2.2787	167	5.3870	2.9803	206	6.6451	2.5595	September	155	5.1667
	2.3816	165	5.5000	2.9749	141	4.7000	2.3826	139	4.4839	2.0230	175	5.6452
Outubro	4.5806	2.3932	November	136	4.5333	2.6297	152	5.0667	2.5811	136	4.5333	
	2.6043	December	213	6.8710	3.2203	162	5.2258	2.9915	169	5.4516	2.8265	




Figura 5. Repartições do serviço público por mês em 2019.

A representação visual apresentada nas Figuras 6 e 7 detalha os setores envolvidos e seus centros de comando em todo o departamento de Doubs. Os mapas mostram uma porcentagem maior de rupturas do tipo FR em comparação com as rupturas do tipo RP. Em ambos os tipos, os locais mais afetados são Mouthe e Arc-Et-Senans. Da mesma forma, o site Le Russey tem mais rupturas do tipo FR do que do tipo RP. Dessa forma, podemos identificar quais áreas têm mais quebras por tipo, o centro responsável e o tipo de recursos mais necessários. Assim, podemos tomar decisões para melhorar a capacidade de armamento de cada centro e consequentemente aumentar a sua eficiência e minimizar os riscos enfrentados pelos bombeiros.

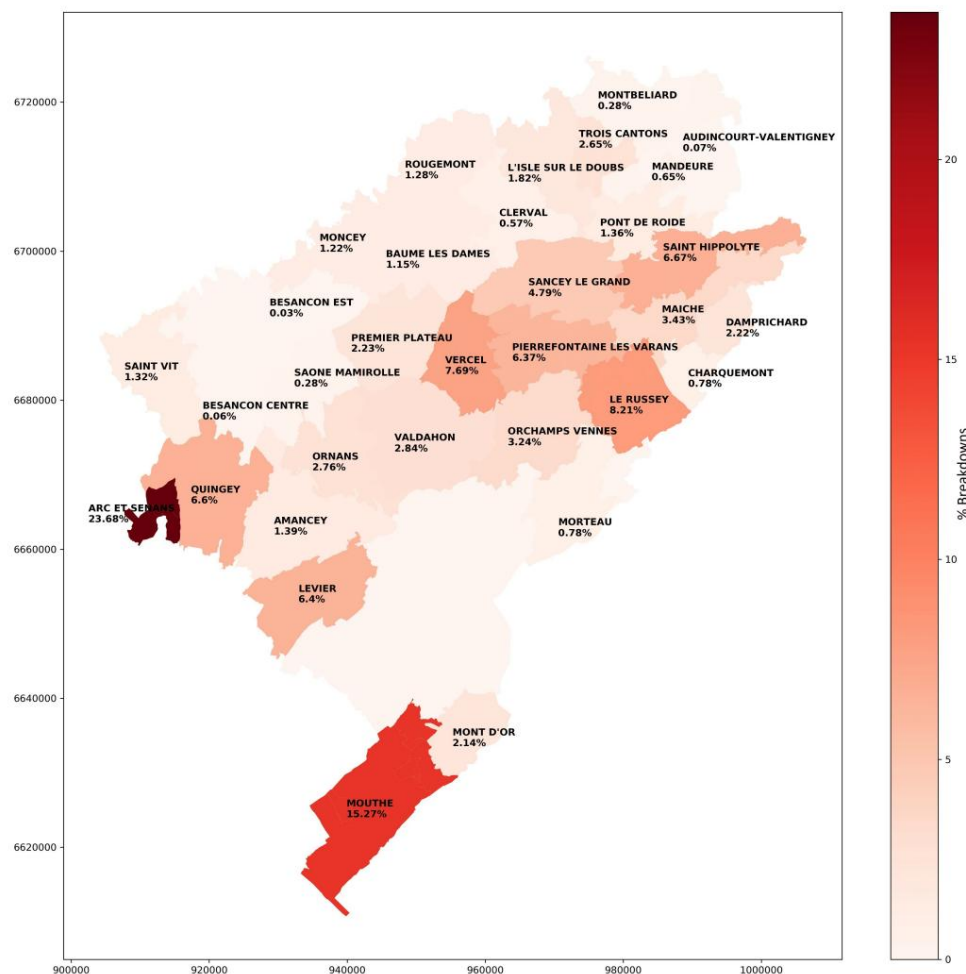


Figura 6. Mapa de Dúvidas 2019—Discriminações do serviço público de socorristas por tipo de setor.

4.2. Resultados e Discussão da Previsão de Avarias Operacionais

Nesta seção descrevemos e discutimos os resultados obtidos para as previsões de quebras operacionais do tipo de serviço público. A Tabela 4 mostra as métricas Raiz do Erro Quadrado Médio (RMSE) e Erro Absoluto Médio (MAE) das previsões feitas para cada mês de 2019 com cada técnica. Na última linha são calculadas as médias em geral, isso permite identificar a técnica com melhores resultados. A Tabela 5 mostra as configurações dos melhores modelos com a técnica XGBoost para cada mês de 2019. A Tabela 6 apresenta as métricas RMSE e MAE calculadas com base em desagregações padronizadas com o método Scikit-Learn MinMaxScaler. Assim, é possível comparar qual mês está apresentando um modelo ruim e analisá-lo. A Figura 8 compara as previsões diárias de avarias no serviço público e o número real delas para cada mês de 2019.

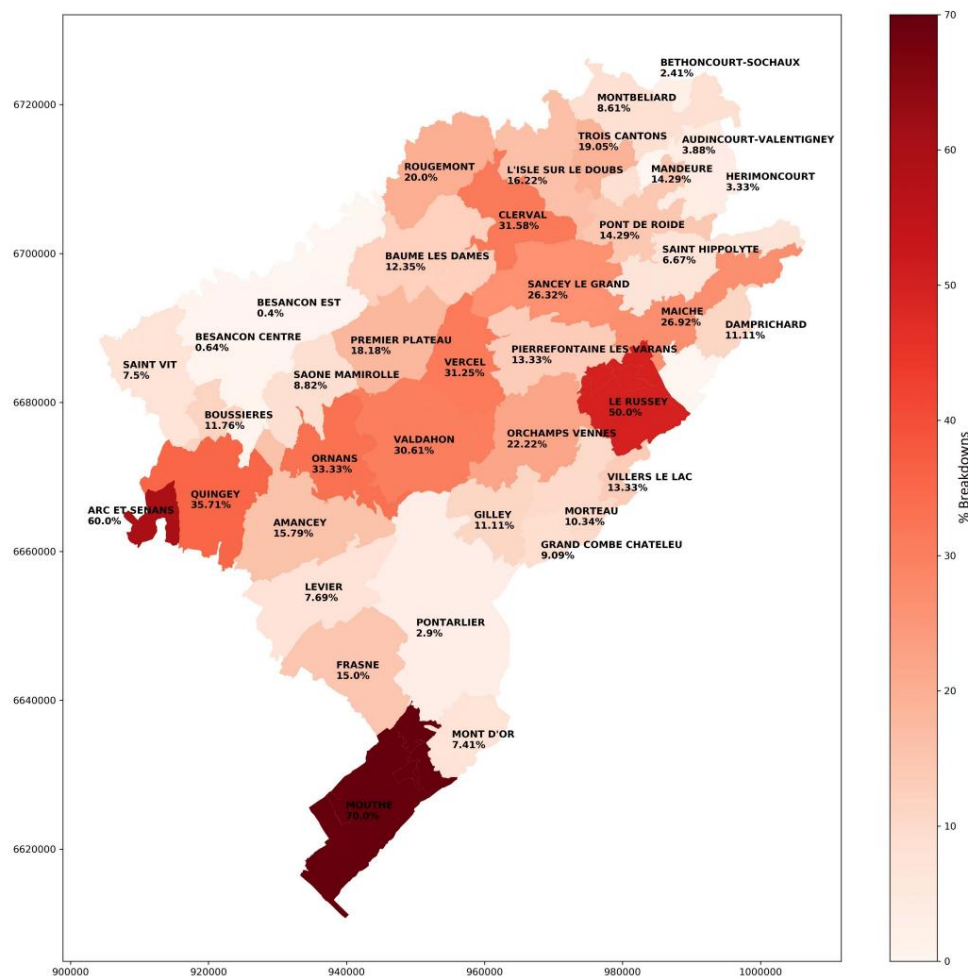


Figura 7. Mapa de Dúvidas 2019—Discriminação do tipo de incêndio no serviço público por setor.

Tabela 4. Previsões de quebras de serviço público por mês para 2019.

Mês	Linha de base		XGBoostGenericName		MLP		BRR		SVM		RF	
	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE
janeiro	3,4641	2,7097	2,2930	1,9032	2,5209	2,0323	2,8455	2,3548	3,5058	2,6774	2,7591	2,1290
fevereiro	3,5355	2,9286	2,0529	1,6429	2,2520	1,7857	3,2950	2,7857	2,4128	1,8214	2,2678	1,8571
março	3,6056	2,9355	2,0791	1,6774	2,2433	1,7419	2,3071	1,8387	2,5400	2,0645	2,2860	1,8065
abril	3,6056	2,9355	2,0791	1,6774	2,2433	1,7419	2,3071	1,8387	2,5400	2,0645	2,2860	1,8065
maio	2,0333	2,9665	2,3333	3,0768	2,4000	2,8925	2,2333	4,1697	2,9354	3,6544	2,8387	3,6323
junho	3,9226	2,8710	5,1897	4,1333	3,0332	2,2667	3,3166	2,4000	4,5753	3,8000	5,0133	3,8667
julho	2,8387	4,0081	3,2258	5,0609	4,0645	5,2976	4,2581	4,5791	3,6774	3,8813	3,2580	2,4561
agosto	2,6396	2,2581	2,4363	2,0645	September	3,2352	2,5333	2,5949	2,0000	2,1909	1,6667	2,7447
setembro	2,9182	2,3226	2,0320	1,5484	2,1627	1,5806	2,4626	1,8710	3,2820	1,8065	2,2361	1,7097
outubro	2,3594	1,9667	2,6708	2,2667	2,5298	2,0667	2,2876	1,8333	December	4,0040	3,2581	2,1850
novembro	1,8065	2,8793	2,2258	2,8819	2,2,387.				1,7419	2,3827	1,8065	2,8793
dezembro	2,2258	2,8819	2,3827						1,8065	2,8793	2,2258	2,8819
Média 3,7686 3,0013 2,5602 2,0240 2,6804 2,0791 3,2016 2,5671 3,1941 2,4937 2,8571 2,2411												

Tabela 5. Hiperparâmetros do melhor modelo XGBoost por mês para 2019.

Hiperparâmetro	Jan.	fevereiro	março	Abr.	Maio	Jun.	Jul.	agosto, setembro	outubro	novembro	dezembro
max_depth	9 285	2 70	4 194	5	9 57	3 75	3 483	3	9 426	9 215	2 267
n_estimators	154 0,2711	0,3870	0,1624	0,5487	0,7399	0,8119	0,8929	0,5059	0,6634	0,5051	50 0,05
learning_rate	0,5314	0,7921	0,9333	0,9987	0,7310	0,5301	0,8417	0,983633030737	0,7777777777777777	0,7777777777777777	0,730
subamostra	0,6431	0,8463	0,5308	0,6080	0,5302	0,6975	0,7269	0,5	0,5301	0,8417	
colsample_bytree	0,6431	0,8463	0,5308	0,6080	0,5302	0,6975	0,7269	0,5	0,5301	0,8417	

Na busca por uma técnica que melhor modele nossos dados, da Tabela 4, deduzimos que nosso modelo de linha de base é superado por todas as outras 5 técnicas. Para cada técnica, o BO foi configurado com 300 pontos iniciais, 100 iterações e a estratégia de exploração denominada Upper Confidence Bound (UCB). A maioria dos melhores modelos para cada mês foi construída com a técnica XGBoost, que obteve em média um RMSE de 2,5602 e MAE de 2,0240. A grade definida para BO aplicada ao XGBoost utilizou os limites: max_depth entre 1 e 10, learning_rate entre 0,05 e 1, estimators entre 50 e 500, subsample entre 0,5 e 1 e colsample_bytree entre 0,5 e 1. Os melhores hiperparâmetros alcançados são descrito na Tabela 5, considerando como função objetivo a regressão com perda quadrada. Além disso, a segunda melhor técnica foi a MLP com RMSE de 2,6804 e MAE de 2,0791. Sua grade para BO considerou os seguintes limites: hidden_layer_sizes entre 50 e 900 neurônios, learning_rate_init entre 0,0001 e 0,1, max_iter entre 0,05 e 0,5, tol entre 0,00001 e 0,01, momentum entre 0,00001 e 0,01, alpha entre 0,00001 e 0,01 e, por padrão, o função de ativação ReLu, solucionador Adam e constante learning_rate. Se olharmos com mais detalhes, maio e setembro são melhor modelados com MLP, e o mês de agosto com RF, pois possuem um RMSE menor. Claro, há uma necessidade de experimentar outras técnicas de aprendizado de máquina.

Por outro lado, os modelos construídos com a melhor técnica até agora, que é o XGBoost, para maio, junho e julho possuem um RMSE maior que 3, o que não indica necessariamente que sejam os meses com os piores modelos. Da Tabela 3 deduz-se que são os 3 meses com maior desvio padrão e isso se reflete ao visualizar as previsões da Figura 8, observamos que são os meses com maior frequência de picos mais altos. Por este motivo, e de forma a comparar as nossas previsões entre meses, as desagregações foram padronizadas entre 0 e 1.

Utilizando o MinMaxScaler, ajustam-se as verdadeiras avarias e transformam-se as rupturas previstas de acordo com a escala definida pelas verdadeiras, os resultados podem ser vistos na Tabela 6. Da Tabela 6, concluímos que na verdade o modelo para junho é um dos melhores em comparação com os outros meses e isso pode ser validado visualmente na Figura 8, assim como o mês de agosto em que é possível perceber claramente um underfitting durante o aprendizado. Assim, podemos identificar os meses que produzem previsões com pouca precisão e estudá-los para saber suas causas, ou seja, reconhecer quais variáveis mais internas e externas devem ser adicionadas no processo de modelagem para melhorar as previsões. Para isso, é preciso analisar quais eventos costumam ocorrer nessas datas na região e no corpo de bombeiros.

Desta forma, a previsão dá-nos uma melhor visão de possíveis perturbações futuras no serviço dos bombeiros, de forma a tomar decisões mais acertadas sobre a reorganização ou aquisição de meios, dependendo sobretudo do número de intervenções previstas, do armamento disponível num determinado tempo e o período mensal.

Tabela 6. Métricas do melhor modelo XGBoost com previsões de quebras em escala por mês para 2019.

Métrica	Jan.	fevereiro	Mar.	Abr.	Maio	Jun.	Jul.	agosto,	setembro	outubro	novembro	dezembro
RMSE	0,2085	0,1866	0,1890	0,2601	0,2436	0,1517	0,2488	0,3070	0,2359	0,1693	0,2258	0,1681
MAE	0,1730	0,1494	0,1525	0,1900	0,1892	0,1133	0,2028	0,2621	0,1818	0,1290	0,1833	0,1340

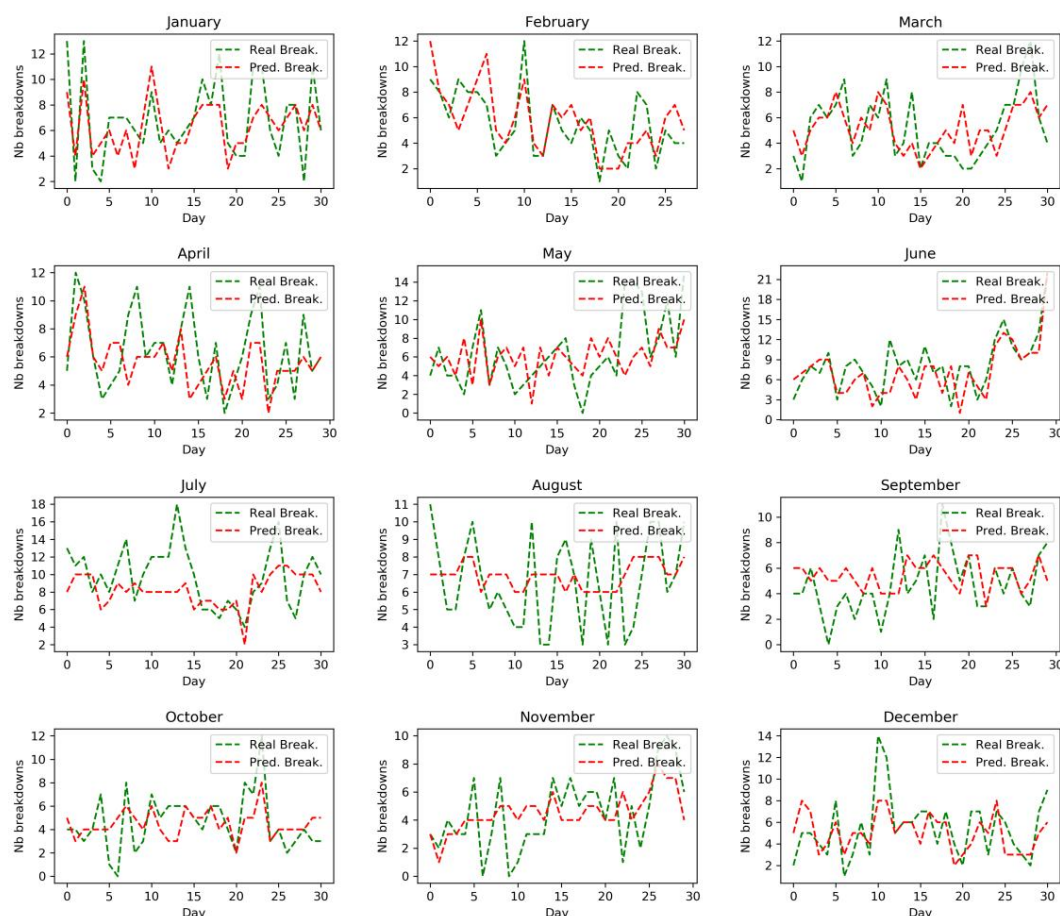


Figura 8. Previsões de quebras de serviço público usando o melhor modelo XGBoost por mês para 2019.

5. Conclusões

Este estudo trata da previsão de rupturas operacionais por mês, mais especificamente avarias de serviço público, tendo como principal objetivo conhecer as futuras possíveis falhas na eficiência da organização e poder combatê-las desenvolvendo estratégias que otimizem a afetação de recursos humanos e materiais. Para o cálculo das avarias foi desenvolvida uma metodologia que permitiu estabelecer indicadores do tipo de rotura e do nível de rotura.

Ao mesmo tempo, construiu-se um modelo matemático para otimizar a procura de um armamento adaptado disponível num determinado centro e tempo, tendo em consideração as competências necessárias de um agente por motor adaptado. Consequentemente, foi possível identificar as causas das avarias, quer por insuficiência do número de motores, quer por falta de agentes e respetivas competências no manuseamento de um motor.

Seleccionámos as rupturas do serviço público para fazer as previsões uma vez que pela sua definição representam as consequências do estado temporário dos recursos afectados em cada centro. Embora esses dados históricos de rupturas de serviço público calculadas sejam pequenos para o momento, construímos modelos de previsão para cada mês incluindo variáveis externas como meteorológicas, epidemiológicas, tráfego, entre outras; e variáveis internas como o número de motores e agentes disponíveis por dia, bem como o número de intervenções, considerando que estas serão fornecidas por outro modelo de previsão que está sendo trabalhado, conforme pode ser encontrado em [2,12,13]. A técnica que apresentou os melhores resultados foi a XGBoost, seguida da MLP.

Assim, é possível reconhecer os setores e seus centros de comando com maior número de falhas por tipo de intervenção. Na verdade, na prática, isso permitiria que os centros fossem fortalecidos para que estivessem preparados para qualquer desastre em qualquer área. Por exemplo, em áreas urbanizadas, os quartéis possuem mais armamento, mas há demora para chegar ao local, que pode ser devido ao trânsito, à falta de armamento disponível ou talvez à má localização dos quartéis; e nas zonas rurais os centros são mais pequenos e têm poucos ou nenhuns bombeiros profissionais e o mesmo com os motores adaptados visto que os incidentes são menos mas não ausentes. Os indicadores ajudariam a definir o aumento ou diminuição do número de motores conforme a intervenção RP ou FR que mais ocorre no setor de um centro; aumento do número de bombeiros profissionais (horário definido) ou voluntários (horários dinâmicos); ou talvez haja bombeiros suficientes mas não tenham a formação necessária para fazer face às intervenções, por exemplo, as intervenções FR requerem seis ou quatro bombeiros consoante o motor, enquanto uma intervenção RP requer três. Além disso, para dirigir um motor FR, é necessária uma licença diferente da licença do motor RP. Por outro lado, a previsão de avarias reforça as estratégias desenvolvidas, uma vez que considera a carga de trabalho que será realizada nos próximos dias juntamente com a organização do armamento atualmente disponível. Desta forma, os recursos poderiam ser reorganizados em alguns setores sem a necessidade de aquisição de novos, a resposta com armamento adaptado a um incidente seria mais eficaz e imediata, as vítimas seriam atendidas o mais rápido possível, as áreas danificadas e as perdas materiais seriam reduzidas, maximizando os benefícios económicos, e não só a segurança e o bem-estar da população estariam garantidos, mas também os bombeiros estariam protegidos contra os riscos das intervenções.

Para trabalhos futuros, há muito o que desenvolver e testar. Por exemplo, criar dados artificiais usando métodos como o Adaptive Synthetic Sampling Method (ADASYN) e fazer previsões de avarias por centro; fazer previsões usando técnicas de séries temporais; testar outros horizontes de tempo para agregação de dados; bem como desenvolver metodologias que recomendem estratégias para a organização ou aquisição de viaturas e bombeiros, por exemplo através da combinação de meta-heurísticas ou da otimização bayesiana. Finalmente, adapte o algoritmo de cálculo de avarias para outros corpos de bombeiros na França e no mundo.

Contribuições dos Autores: Conceituação, GR, CC, GP e SC; Metodologia, GR, CC e SC; Software, SC e CG; Validação, CC, GP e SC; Análise Formal, CC e SC; Investigação, GR, CC e SC; Recursos, GR, CC e GP; Redação—Preparação do Rascunho Original, SC e CG; Visualização, CC e SC; Supervisão, GR e CG Todos os autores leram e concordaram com a versão publicada do manuscrito.

Financiamento: Esta pesquisa não recebeu financiamento externo.

Agradecimentos: Este trabalho foi financiado pela SDIS du Doubs, com o apoio do Ministério Francês de Ensino Superior e Pesquisa (gerenciado pela Associação Nacional de Pesquisa e Tecnologia (ANRT) para a tese CIFRE (N 2019/0372).

Conflitos de Interesse: Os autores declaram não haver conflito de interesse.

Referências

1. Cerna, S.; Guyeux, C.; Arcolezi, HH; Couturier, R.; Royer, G. Uma comparação de LSTM e XGBoost para prever intervenções de bombeiros. Em *Tendências e Inovações em Sistemas e Tecnologias de Informação*; Springer International Publishing: Cham, Suíça, 2020; pp. 424–434. [\[CruzRef\]](#)
2. Couchot, JF; Guyeux, C.; Royer, G. Prevendo anonimamente o número e a natureza das operações de combate a incêndios. Nos *Anais do 23º Simpósio Internacional de Aplicações e Engenharia de Banco de Dados em—IDEAS19*, Atenas, Grécia, 10–12 de junho de 2019; ACM Press: Nova York, NY, EUA, 2019. [\[CrossRef\]](#)
3. Guyeux, C.; Nicod, JM; Varnier, C.; Masry, ZA; Zerhouny, N.; Omri, N.; Royer, G. Previsão de bombeiros usando redes neurais: um estudo de caso real. Em *Avanços em Sistemas Inteligentes e Computação*; Springer International Publishing: Cham, Suíça, 2019; pp. 541–552. [\[CruzRef\]](#)
4. Lan, CH; Chuang, LL; Chen, YF Eficiência de desempenho e estratégia de alocação de recursos para o corpo de bombeiros com a consideração estocástica. *Int. J. Technol. Gestão de Políticas* **2009**, *9*, 296. [\[CrossRef\]](#)

5. Morello, TF; Ramos, RM; Anderson, LO; Owen, N.; Rosan, TM; Steil, L. Previsão de incêndios para formulação de políticas : Melhorando a precisão da alocação de brigadas de incêndio na Amazônia brasileira. *Eco. Econ.* **2020**, *169*, 106501. [\[CruzRef\]](#)
6. Bjarnason, R.; Tadepalli, P.; Fern, A.; Niedner, C. Otimização baseada em simulação de colocação de recursos e resposta de emergência. In *Proceedings of the IAAI, Pasadena, CA, EUA*, 14–16 de julho de 2009.
7. Dibene, JC; Maldonado, Y.; Vera, C.; de Oliveira, M.; Trujillo, L.; Schütze, O. Otimizando a localização de ambulâncias em Tijuana, México. *Comput. Biol. Med.* **2017**, *80*, 107–115. [\[CruzRef\]](#) [\[PubMed\]](#)
8. Carvalho, A.; Captivo, M.; Marques, I. Integrando os problemas de despacho e realocação de ambulâncias maximizar a preparação do sistema. *EUR. J. Opera. Res.* **2020**, *283*, 1064–1080. [\[CruzRef\]](#)
9. Lin, AX; Ho, AFW; Cheong, KH; Li, Z.; Cai, W.; Chee, ML; Ng, YY; Xiao, X.; Ong, MEH aproveitando técnicas de aprendizado de máquina e engenharia de recursos multinaturais para previsão de demanda de ambulância regional diária nacional . *Int. J. Environ. Res. Public Health* **2020**, *17*, 4179. [\[CrossRef\]](#)
10. Fiorucci, P.; Gaetani, F.; Minciardi, R.; Sacil, R.; Trasforini, E. Alocação dinâmica de recursos para gestão de riscos de incêndios florestais. In *Proceedings of the 15th International Workshop on Database and Expert Systems Applications, Zaragoza, Espanha*, 30 de agosto–3 de setembro de 2004; IEEE: Piscataway, NJ, EUA, 2004. [\[CrossRef\]](#)
11. Zhou, S.; Erdogan, A. Um modelo de otimização espacial para alocação de recursos para supressão de incêndios florestais e evacuação de residentes. *Comput. Ind. Eng.* **2019**, *138*, 106101. [\[CrossRef\]](#)
12. Cerna, S.; Guyeux, C.; Arcolezi, HH; Lotufo, ADP; Couturier, R.; Royer, G. Memória de curto prazo longa para prever as intervenções dos bombeiros. In *Proceedings of the 6th International Conference on Control, Decision and Information Technologies (CoDIT 2019), Paris, França*, 23–26 de abril de 2019. [\[CrossRef\]](#)
13. Cerna, S.; Guyeux, C.; Arcolezi, HH; Royer, G. Impulsionando métodos para prever as intervenções dos bombeiros. Nos Anais da 11ª Conferência Internacional sobre Sistemas de Informação e Comunicação (ICICS) de 2020, Bangkok, Tailândia, 15–16 de dezembro de 2020; pp. 001–006.
14. Arcolezi, HH; Couchot, JF; Cerna, S.; Guyeux, C.; Royer, G.; Al Bouna, B.; Xiao, X. Previsão do Número de Intervenções de Bombeiros por Região com Dados Baseados em Privacidade Diferencial Local. *Comput. Seguro.* **2020**, *96*, 101888. [\[CrossRef\]](#)
15. Beal, L.; Colina, D.; Martin, R.; Hedengren, J. GEKKO Suíte de Otimização. *Processos* **2018**, *6*, 106. [\[CrossRef\]](#)
16. Météo-France. Données Publiques. Disponível online: https://donneespubliques.meteofrance.fr/?fond=produit&id_produit=90&id_rubrique=32 (acessado em 2 de julho de 2020).
17. Sentinelas. Le Réseau Sentinelles. Disponível online: <https://www.sentiweb.fr/?page=table> (acessado em 2 de julho de 2020).
18. Bison-Futé. Les Prévisions de Trafic. Disponível online: <https://www.bison-fute.gouv.fr> (acessado em 2 de julho de 2020).
19. Rhodes, B. Skyfield: Posições de nível de pesquisa de alta precisão para planetas e gerador de satélites terrestres. *arXiv* **2019**, arxiv:1907.024.
20. Pedregosa, F.; Varoquaux, G.; Gramfort, A.; Michel, V.; Thirion, B.; Grisel, O.; Blondel, M.; Prettenhofer, P.; Weiss, R.; Dubourg, V.; e outros Scikit-learn: aprendizado de máquina em Python. *J. Mach. Aprender. Res.* **2011**, *12*, 2825–2830.
21. Chen, T.; Guestrin, C. XGBoost: Um sistema de aumento de árvore escalável. Nos Anais da 22ª Conferência Internacional KDD '16 ACM SIGKDD sobre Descoberta de Conhecimento e Mineração de Dados, San Francisco, CA, EUA, 13–17 de agosto de 2016; ACM: Nova York, NY, EUA, 2016; pp. 785–794. [\[CruzRef\]](#)
22. Graves, A. Rotulagem de sequência supervisionada com redes neurais recorrentes; Springer: Berlim/Heidelberg, Alemanha, 2012.
23. Kingma, DP; Ba, J. Adam: Um método para otimização estocástica. *arXiv* **2014**, arxiv:1412.6980.
24. Karabatsos, G. Estimativa de Verossimilhança Marginal Rápida do(s) Parâmetro(s) Ridge na Regressão Ridge e Regressão Ridge Generalizada para Big Data. *arXiv* **2014**, arxiv:1409.2437.
25. Bishop, CM Reconhecimento de Padrões e Aprendizado de Máquina (Ciência da Informação e Estatística); Springer: Berlim/Heidelberg, Alemanha, 2006.
26. Chang, CC; Lin, CJ LIBSVM. *ACM Trans. Intel. Sist. Tecnol.* **2011**, *2*, 1–27. [\[CruzRef\]](#)
27. Breiman, L. Florestas aleatórias. *Mach. Aprender.* **2001**, *45*, 5–32.:1010933404324. [\[CruzRef\]](#)
28. Wu, J.; Chen, X.; Zhang, H.; Dong Xiong, L.; Lei, H.; Deng, S. Otimização de Hiperparâmetros para Modelos de Machine Learning Baseados em Otimização Bayesiana. *J. Elétron. ciência Tecnol.* **2019**, *17*, 26–40.

29. Shahriari, B.; Swersky, K.; Wang, Z.; Adams, RP; de Freitas, N. Tirando o Humano do Loop: Uma Revisão da Otimização Bayesiana. *Proc. IEEE* **2016**, *104*, 148–175. [[CruzRef](#)]
30. Nogueira, F. Otimização bayesiana: ferramenta de otimização global restrita de código aberto para Python. 2014. Disponível online: <https://github.com/fmfn/BayesianOptimization> (acessado em 2 de julho de 2020).



© 2020 pelos autores. Licenciado MDPI, Basel, Suíça. Este artigo é um artigo de acesso aberto distribuído sob os termos e condições da Creative Commons Attribution

(CC BY) (<http://creativecommons.org/licenses/by/4.0/>).